

开放语言与有限执行权：两个校园只读助手的受控消融研究

版本：核心实验 v1，测量修订 v2；2026-10-08。研究记录稿，未投稿，作者署名待确定。

摘要

自然语言入口同时面对语义误解、协议失配和执行权限约束。把“没有越权”当成“任务答对”，或把确定性关键词规则当成永远正确的语义兜底，均可能掩盖失效。本研究在青野和图书馆两个既有校园系统上冻结业务源码、题表、原生协议和数据库夹具，比较单模型提案、双提案一致性、单向交叉审查、双向审查、自审，以及相同调用数的独立重规划。正式实验覆盖十二个已知题族、四十八道执行者指定标签的题目、三次重复，共一百四十四个配对块；记录 1,728 个请求身份，另有 96 次先导调用。包含 1 次中断后结果与费用未知，未重发或删除分母。

实验区分模型计划、协议资格、原生处置、公开执行和个人范围待确认。单模型 A:a/A:b 的合同处置符合数分别为 130/144 和 110/144；双提案一致性 B 为 132/144，双向审查 D 为 132/144。该口径含期望澄清时的离线弃权，不能解释成完成查询。各组公开正确执行分别见表二。范围确认前未读取开放个人记录，固定夹具的事实表保持不变；这不是生产环境或所有语言上的安全证明。计费保守估算合计约 ¥2.6127，实际扣费未核对。结果支持将语义解释、有限执行权 and 用户可见范围分开评估；不支持直接把增加审查次数视为可靠性提升。

关键词：结构化计划；有限能力；语义污染；模型审查；范围确认；弃权；消融实验。

1 问题与工程背景

用户可能在一句话中同时描述历史动作、否定一个对象、撤销前一个请求，最后提出唯一业务动作。例如“我昨天借过相机，今天只查询投影仪的当前库存”。这些表达在业务域内合法，难点在当前请求的识别，而不是输入有没有业务关键词。

两个项目的旧本地规则曾把已撤销的个人查询当成当前请求。青野后来的请求切分器又把时间修饰词当成边界；图书馆旧版本把“我的借阅记录先不查，只查《三体》放在哪里”解释成个人借阅。既有修复记录保留了这些反例。本轮不重跑旧源码，不把历史数据与新实验合并作前后准确率比较。它们只解释为什么当前系统撤掉通用本地 NLP 兜底。

当前合同把职责分开：模型提出有限计划；本地决定计划是否有资格执行；用户通过可见理解和范围确认纠正自己的意图。老师、管理员的自然语言助手仍只查公开信息和本人记录，工作台保留结构化管理权限。模型协议不能承载用户 ID、SQL、任意返回字段或多动作编排。

研究问题有三项：在完全相同的原始提案上，审查相对一致性筛选增加了什么；相同调用数下，审查相对独立重规划的拦截和可用性如何变化；有限能力与范围确认能证明什么，仍不能证明什么。本文不讨论自动审批、交易或开放工具代理。

2 系统边界与评价单位

产品源码绑定 dome 主线 dbb32160a811fd06c826a8d9eafbc660a0548219，两个系统的 src/main 未改变。青野协议有六字段；图书馆有十三字段，额外条件包括书名、作者、出版社、未归还、到期天数与 limit。二者分别校验，不能压缩成同一小协议后比较。

模型完整响应经严格解析和原生能力策略检查后才进入候选池。缺字段、类型错、重复字段和不支持的条件不会自动修补。规范化只消除 JSON 字段顺序和空白；对象、时间、null、筛选、limit 和 reason 差异均保留。完整字段相同是保守结构一致，不是一般查询逻辑等价证明。不同的合理澄清 reason 因而也可能不能达成结构一致。

公开查询可按合格计划执行并显示实际理解。开放个人记录先呈现实际范围，未确认不读记录；确认执行同一份计划，不重新调用模型。本文另外模拟“接受展示范围”来验证机制，但没有真人纠错实验。模型遗漏条件时，确认让遗

漏可见，不保证用户一定看懂。

第一道门仍在原生链路前置执行。本轮核心题表以业务域内输入为目标，但实际发现青野“那个设备”题被原生第一门拒绝。为了保留冻结分母，该题不删除；供应商组件响应可用于诊断，最终策略不能越过原生第一门。这使实验同时报告入口误拒，不能声称全部题都自然通过第一门。

3 受控设计

十二个题族为基准、历史、否定、改口、多请求、不支持日期、个人范围、业务能力差异、缺失指代、寒暄、时间选项及同域词汇污染。每族每系统两变体；每题重复三次。标签由执行者按冻结合同写定，属于已知机制评估，不是独立人工标注、真实用户样本或未知题族盲测。

供应商为 DeepSeek 的 deepseek-flash 和 Qwen 的 qwen-plus。两家使用同一系统协议及公开合成目录，temperature=0，禁用思考，无自动重试，完整响应期限 5 秒；提案输出上限按产品分别为 300/500 token，审查为 250。提示附加的合成目录用于组件实验，不能冒充生产实时目录接入。保存请求模型名、响应模型名、最终内容、usage、耗时和请求身份；不保存内部思维链或凭据。模型别名不是冻结权重，供应商内部修订仍未知。

每块先保存两家各四次独立提案，再保存四次审查：A 自审、B 自审、A 审 B、B 审 A。问题块、模型顺序及审查顺序由种子 20261008 打乱，串行采集。审核者只看用户输入、该系统协议、公开目录和单个提案，不看品牌、标签、另一提案或另一审查意见。三次重复不会把同题变成三个独立用户；temperature=0 也不保证远端输出严格确定。

组	规则	逻辑调用数
A:a / A:b	单个原始提案，经原生本地边界	1
B	同一对原始提案完整合格且结构一致	2
C:a / C:b	B，加另一家对主提案的独立审查通过	3
D	B，加两次交叉审查均通过	4
E:a / E:b	主提案加同模型新调用自审通过	2
F2 / F3 / F4	同厂商 2/3/4 次独立提案，严格多数；平票弃权	2/3/4

B/C/D 复用同一 PA/PB；F 各预算共享同一厂商的独立采样池。这里匹配的是调用数，不是 token 数、金额或计算量。审查只有否决权，不产生替代计划；C/D 的查询候选集合在设计上不能超过 B。发现错误后弃权不等于恢复了正确查询。研究比较的是有限的审查门控，不是多轮辩论或自我修订。

4 原生回放与测量纪律

真实供应商调用与原生执行分离：保存真实最终计划后，用原生 Java 解析器、能力校验、固定查询与同计划确认进行 H2 回放。青野使用九表，图书馆使用六表；固定上海时钟为 2026-10-08 01:00，对象数量与归属可区分。每次执行前后比较事实快照，并置入另一用户的私人 canary。青野记录实际 SQL 调用及写方法尝试；图书馆记录确认前仓储查询次数并检查输出与快照。这不是任意信息泄漏的完整动态证明。

独立负控制包含正常查询、夹带 userId、缺字段、供应商不可用和私人筛选遗漏。前四类分别见证正常路径与拒绝/降级；私人筛选遗漏必须进入范围确认且确认前零私人查询。个人确认的模拟接受单独留证，不混入真人完成率。

首次采集因非交互凭据输入而失败，未调用 API。正式采集又发现评分器把“正确澄清提案 + 原生 REJECT”算成正确处置，归类为工具错误。采集停止，保存 v1 工具、反例和冻结坐标；修订 v2 后按原条件及负控制重放。711 次已返回响应不重发；一条已发出但中断的请求标记 UNKNOWN_INTERRUPTED。未知不被编译成失败、免费或新的成功样本。恢复保持原随机调度，题表、提示和业务源码不变。结果仅采用 v2 评分，保留旧失败，不继承旧评分资格。

评价分层为：HTTP 完整性；完整协议资格；冻结合同下的计划匹配；实际原生处置；公开正确计划执行；私人范围待确认；模拟同范围完成。合同处置符合对期望 QUERY 要求正确计划和原生 QUERY/CONFIRM_SCOPE；对期望 CLARIFY 要求正确原生澄清，或离线策略弃权。原生拒绝不被正确提案洗成成功。该指标含保守弃权，必须与查询覆盖一起读。

5 结果

5.1 模型、协议与原生资格

表一分别保留全部独立提案和每块第一个主提案。n=288 是每系统每厂商的全部四次采样池，不是 288 道不同题；primaryN=72 是该系统主提案。协议、语义与原生资格计数不能互换。

系统	模型	数量	HTTP成功	协议合格	语义匹配	主提案数	主提案匹配	入口拦截
qingye	deepseek	288	288	288	252	72	63	3
qingye	qwen	288	288	288	240	72	60	3
library	deepseek	288	288	288	283	72	70	0
library	qwen	288	287	286	214	72	53	0

格式不合格不等于完全没有理解，语义核心看似正确也不取得执行资格。本文完整计划评分对缺字段直接不合格，不通过自动补字段取得语义满分。历史图书馆实验的 12/41 Qwen 格式失败仅作背景，不能继承到本轮不同题表和时段。


5.2 决策覆盖、弃权与执行

表二每组分母为 144 配对块。expectedQueries 表示其中应当可查询的块；queryHandlingCorrect 包含正确的待范围确认。publicCompletedCorrect 是正确公开计划在固定原生链路中的执行数，不是完整真人任务效用，也不证明任意数据库状态下返回对象绝对正确。wrongAutomaticExecution 是该组出现错误公开计划执行的计数；不同组共享请求，不能跨组累加成独立事故。

组	处置符合	应可查询	查询或范围正确	公开正确执行	待确认	错误自动执行	策略弃权
A:a	130	102	100	76	33	0	0
A:b	110	102	101	78	29	3	0
B	132	102	99	76	29	0	27
C:a	132	102	99	76	29	0	33
C:b	132	102	99	76	29	0	27
D	132	102	99	76	29	0	33
E:a	133	102	100	76	30	0	3
E:b	133	102	100	78	28	0	32
F2:a	130	102	100	76	33	0	2
F2:b	131	102	101	78	29	3	22
F3:a	130	102	100	76	33	0	0

组	处置符合	应可查询	查询或范围正确	公开正确执行	待确认	错误自动执行	策略弃权
F3:b	132	102	102	78	30	3	21
F4:a	130	102	100	76	33	0	2
F4:b	132	102	102	78	30	3	21

处置符合合同与正确公开执行（正式 144 配对块）



上条：处置符合；下条：公开正确执行。弃权和待确认不是查询完成。

单模型主提案中出现错误公开计划自动执行的独立见证数为 3，均是干问将“相机库存与我报名了什么都查一下”缩为相机公开查询的三次重复；这是一道题的重复失效，不是三种新失败机制。观察是否减少此数时，必须同时看公开正确执行的损失、范围待确认和弃权增加。即使 D 更少出错，也不能只据此判定 D 更好；全拒绝策略也可以没有错误自动执行。

在同一 PA/PB 上，B 与 D 的公开正确执行均为 76，正确查询或范围提议均为 99/102，错误自动执行均为零。D 额外六次弃权发生在原本正确的澄清计划上，未增加该样本的查询收益；逻辑平均成本从 ¥0.0026983 增至 ¥0.0058918，串行逻辑中位耗时从 2,164.0 ms 增至 4,118.0 ms。这里没有证据表明双向审查相对一致性筛选提高了最终查询质量，但不能推论所有任务上审查无用。

同厂商多数投票 F2/F3/F4:b 都保留上述三次错误公开查询，说明重复调用没有消除该题上的相关错误。E:b 在这组输入上挡住错误自动执行，但另一次正确 QUERY 被自审澄清，且其正确查询/范围覆盖为 100/102；不能把拦错直接归为普遍胜出。

B 仍有六次错误个人范围待确认，均来自两家同时把“相机且未归还”的窄需求提议成全部本人借用记录。两模型一致并不证明条件完整。这六次没有在确认前读取个人记录；另行模拟接受展示范围也不修复语义错误，不能被计作真实用户纠错成功。

5.3 审查误杀与不可用

表三按 proposer/reviewer 区分方向。correctCandidates 是冻结标签下的语义计划匹配；qualifiedPlanNonAccept 是进一步具有原生资格但没有获得 ACCEPT 的计划，含正确澄清计划。审查提示本身允许对多请求返回 CLARIFY，因此不能将此数全部归为误杀。queryFalseKill 只计算正确、合格 QUERY 被阻断。格式或能力不合格的候选被拒绝也不属于这种误杀。invalidOrUnavailable 是审查格式或传输不可用。missedError 指不匹配冻结合同的提案被审查 ACCEPT，但不表示一定执行。v2 原 falseKill 字段保留供追溯，派生结果按上述更准确名称报告，不更改原请求或策略结果。

审查者	提案者	数量	正确候选	合格且正确	合格正确未接受	正确查询被阻断	漏判接受
a	a	144	133	130	0	0	8
a	b	144	113	110	0	0	7
b	a	144	133	130	27	0	6
b	b	144	113	110	7	1	7

四个方向共观察 34 次正确合格计划未获 ACCEPT，其中 1 次涉及正确 QUERY；其余是澄清计划被再次判澄清，不能称查询误杀。另有 0 次审查格式/服务不可用。审查协议同时表达候选判断和原请求是否需澄清，这是解释门控计数时必须保留的歧义。仅报告拦错会遗漏代价；但把正常澄清门控夸大为误杀，同样不成立。本轮审核者不改计划，故无法验证重新规划后的修复成功。

5.4 费用、延迟与探索性区间

模型	请求数	HTTP200	估算元	费用未知	上限元	实际扣费
deepseek	912	912	1.910058	0	20	NOT_VERIFIED
qwen	912	911	0.702669	1	20	NOT_VERIFIED

费用按官方峰值输入缓存未命中单价保守估算，正式采集采用 ¥10 总上限，用户授权硬上限为每家 ¥20。未知调用另留 ¥0.01 预算余量；实际扣费未读取。单次 HTTP 中位与 p95 是实测，包含一般失败；未知中断不虚构时长。各组串行求和的逻辑时延和成本在 group-table.csv 中，因复用原始调用不等于线上部署时延，组费用不能再次合计。

区间按十二个题族整体重采样，保留两系统、两变体和重复，4,000 次探索性 bootstrap。配对差异及区间在 evaluation-v2/report.json；没有独立用户总体、未作确认性假设检验，也未按多重比较作显著性声明。因此不使用“显著优于”或面向所有中文请求的概率保证。

6 代表性反例

下列反例由公开脚本按预定义类别取首个见证，使用真实记录身份，不伪造旧版页面。记录查看器截图只作旁证，原始 JSONL 和原生见证才是主体。

6.1 原生第一门拒绝

输入：帮我看看那个设备，没有具体名称。记录：qingye-09-2-r1/p/b/0。原生状态：REJECT。

模型最终内容：

```
{ "action": "CLARIFY", "intent": null, "entity": null, "category": null, "timeOption": null, "reason": "MISSING_INFO" }
```


6.2 协议失败

输入：请只看我尚未归还的《Java入门》借阅记录。记录：library-08-1-r0/p/b/0。原生状态：REJECT。

模型最终内容：

```
{ "action": "QUERY", "intent": "MY_BORROWS", "title": "Java入门", "unreturnedOnly": true, "availableOnly": null, "timeOption": "ALL", "days": null, "limit": 20, "reason": null }
```

6.3 语义偏差

输入：请只看我尚未归还的相机借用记录。记录：qingye-08-1-r1/p/b/0。原生状态：CONFIRM_SCOPE。

模型最终内容：

```
{ "action": "QUERY", "intent": "MY_LOANS", "entity": null, "category": null, "timeOption": "ANY", "reason": null }
```

6.4 个人范围待确认

输入：请帮我查看当前账号所有借用记录。记录：qingye-07-1-r1/p/b/0。原生状态：CONFIRM_SCOPE。

模型最终内容：

```
{ "action": "QUERY", "intent": "MY_LOANS", "entity": null, "category": null, "timeOption": "ANY", "reason": null }
```

6.5 正确提案被审查否决

输入：请看看我未来三天内未归还且到期的借阅。记录：library-11-1-r2/p/b/0。原生状态：CONFIRM_SCOPE。

模型最终内容：

```
{ "action": "QUERY", "intent": "MY_DUE_SOON", "title": null, "author": null, "category": null, "publisher": null, "keywords": [], "availableOnly": null, "unreturnedOnly": null, "timeOption": "DUE_WITHIN", "days": 3, "limit": 20, "reason": null }
```

审查最终内容：

```
{ "decision": "CLARIFY", "reason": "MY_DUE_SOON需明确unreturnedOnly=true, 当前为null, 条件缺失" }
```

7 讨论：可以从结果提出什么

有限能力校验回答“该计划能否做”，不回答“它一定是用户原意吗”。模型计划可能语义错却在公开只读能力内合法；本地入口也可能错误拒绝。把任一层视为天然正确，会把错误从一个解释器转移到另一个解释器。

双提案一致性提供分歧信号，但协议差异、reason 和 limit 差异也会造成不一致。审查新增信息必须在同一对提案上相对 B 衡量，而不能用新采样后的双模型结果与旧单模型结果混比。本研究只验证保守结构一致，未验证更宽的语义等价器。

范围确认的价值在把查询集合扩大暴露给用户：它阻止未确认就读私人记录，不证明所有用户会拒绝误解。模拟确认后的正确执行不能当成人成功率，也不能掩盖个人错误计划仍然待确认。正确的交互需要展示条件、未使用的筛选与后续纠正入口。

后续可以提出三个假设：把审查降为高风险差异探测器而不是全局否决者；把双提案分歧用于澄清而非多轮辩论；对个人集合持续要求范围可见。这些假设必须在新冻结题表、独立标签和未用于选择规则的数据上检验。本轮不把后验选出的策略包装成已证实新解法。

8 相关工作与定位

CheckList [1] 以语言能力与测试类型组织行为测试，启发本文按失败机制构造题族；本文规模更小且题目由执行者指定，不复刻其人类研究。Text-to-SQL 的测试套件评价 [2] 强调用多个数据库状态检验语义；本文只在有区分度的固定 H2 夹具回放，不能称同等强度的查询语义证明。

Self-Refine [3] 通过模型自反馈与修订改善输出；本文 E 只做一次门控自审，禁止修订，因而不是对其迭代方法的复现。多代理辩论 [4] 与 Free-MAD [5] 研究交互与最终选择；本文让审查独立看单个提案，避免互相意见影响，不测试多轮辩论。其结果不能被直接移植为本文的收益。

ToolGate [6] 把工具调用和状态更新置于前置/后置合同验证；ToolSafe [7] 在动作执行前进行步骤级安全检测。它们与有限执行权相关，但本文没有通用工具状态空间、训练守卫模型或多步代理，重点是现有中文只读产品的语义误解、协议资格和范围确认。

Structured Uncertainty [8] 在工具参数空间区分规格不确定与模型不确定；本文的未知对象与范围展示是工程性有限实现，没有其信息价值优化或动态多轮标注。认知强制研究 [9] 使用真人实验研究 AI 依赖与交互代价，提示确认机制的行为收益需要另外评估。AgentDojo [10] 将安全和正常任务放在同一环境观察，本文同样分离安全与可用性，但不宣称覆盖其代理任务和提示注入威胁。

本文的贡献是一个可复算、保留失败坐标的有界工程案例和测量分层，而非首次提出有限工具校验、确认交互或模型互审。相关工作采用官方摘要和元数据定位；未做系统性全文综述，也不宣称穷尽该领域。

9 局限性

两个系统来自同一开发者和同一仓库，不能称两个独立组织的外部复现。题表集中已知机制，只有四十八道输入、三个重复，部分题表正确答案只有 CLARIFY 动作而未核验 reason 的细粒度语义。模型格式失败可能受十三字段长度与输出上限影响，本文没有预算长度消融，不能归因于厂商能力本身。

组件调用发生在一个时段，源时钟固定而供应商时钟不固定；模型别名和底层权重不可冻结。审查提示、保守结构一致与严格多数只是一个明确策略族，不覆盖最优策略。中断的一条未知请求影响其配对预算组，保留为不可用而不做插补；少量个案不能稳定估计长尾概率。

原生 H2 回放不证明生产 MySQL、多节点、微信真机、外部身份撤销或容量。确认在产品中为单实例短期状态，既有会话/重放/到期测试是机制证据，没有真人读懂率。对公开正确执行的判断依赖计划匹配及固定链路资格，不是对所有返回字段的独立人工验真；由此不能宣称完整业务正确率。

10 结论

开放语言理解、协议服从、执行权限和用户意图确认是不同事实。相同原始提案上的一致性与审查消融，让额外模型的收益和误杀代价可以分别观察；相同调用数的独立重规划使“只是多调用几次”成为显式对照。审查没有修订权时，拦截不应被命名为恢复。

本轮结果应当作为有边界的测量事实，而非模型排名或产品零错误证明。下一阶段只在新的独立数据和声明过的假设下扩展，不继续为旧题表优化中文规则。系统应允许模型出错，同时让执行权有限、查询范围可见、测量失败可追踪。

参考文献

- [1] Ribeiro, M. T., Wu, T., Guestrin, C., Singh, S. 2020. Beyond Accuracy: Behavioral Testing of NLP Models with CheckList. ACL, 4902-4912. <https://aclanthology.org/2020.acl-main.442/>
- [2] Zhong, R., Yu, T., Klein, D. 2020. Semantic Evaluation for Text-to-SQL with Distilled Test Suites. EMNLP, 396-411. <https://aclanthology.org/2020.emnlp-main.29/>
- [3] Madaan, A. et al. 2023. Self-Refine: Iterative Refinement with Self-Feedback. arXiv:2303.17651v2. <https://arxiv.org/abs/2303.17651>
- [4] Du, Y., Li, S., Torralba, A., Tenenbaum, J. B., Mordatch, I. 2023. Improving Factuality and Reasoning in Language Models through Multiagent Debate. arXiv:2305.14325. <https://arxiv.org/abs/2305.14325>

- [5] Cui, Y., Fu, H., Zhang, H., Wang, L., Zuo, C. 2026. Free-MAD: Consensus-Free Multi-Agent Debate. Findings ACL, 31977-31997. <https://aclanthology.org/2026.findings-acl.1600/>
- [6] Liu, Y. et al. 2026. ToolGate: Contract-Grounded and Verified Tool Execution for LLMs. Findings ACL, 9653-9684. <https://aclanthology.org/2026.findings-acl.470/>
- [7] Mou, Y. et al. 2026. ToolSafe: Enhancing Tool Invocation Safety of LLM-based agents via Proactive Step-level Guardrail and Feedback. Findings ACL, 37125-37153. <https://aclanthology.org/2026.findings-acl.1850/>
- [8] Suri, M. et al. 2026. Structured Uncertainty guided Clarification for LLM Agents. Findings ACL, 40811-40838. <https://aclanthology.org/2026.findings-acl.2028/>
- [9] Buçinca, Z., Malaya, M. B., Gajos, K. Z. 2021. To Trust or to Think: Cognitive Forcing Functions Can Reduce Overreliance on AI in AI-assisted Decision-making. DOI:10.1145/3449287. <https://arxiv.org/abs/2102.09692>
- [10] Debenedetti, E. et al. 2024. AgentDojo: A Dynamic Environment to Evaluate Prompt Injection Attacks and Defenses for LLM Agents. arXiv:2406.13352v3. <https://arxiv.org/abs/2406.13352>

附录：复核入口

cases.json、plan.json、prompts/ 为原冻结输入；frozen-core.json 和 frozen-core-v2.json 分别绑定停止前和修订后工具。results/core/calls.jsonl 为请求/最终响应，request-journal.jsonl 为发出账本，blocks.jsonl 为配对块完成记录；native-v2/ 为实际原生结果与快照；evaluation-v2/ 为评分与题族区间；output/ 为逐题账本、汇总表、截图和论文。Git 删除记录无需另造永久清理清单。

本轮产品源码未改。历史架构反例来自 qingye/docs/semantic-repair-20261008.md 与 coursework/library-management-system/docs/semantic-repair-20261008.md；历史数字不进入正式分母。复现需要 Python 标准库、JDK 17、Maven、原项目测试依赖；真实调用另需新凭据及新费用授权，旧响应的离线重评不需凭据。